

1. LLM 辅助模拟电路参数优化实验报告

摘要：本实验基于 AnalogGym 开源 benchmark 的 NMCF 放大器电路 (SKY130 PDK)，系统对比了四种参数优化方法——强化学习 (DDPG+R-GCN)、贝叶斯优化 (GP+EI)、自建 LLM 增强 BO (LLM+BO) 以及 LLANA (LLM 完全替代 GP 的 BO 框架)。在 24 维连续参数空间上，BO 以 20 次评估、FoM = -1.39 取得最优效率；RL 以 200 次评估、FoM = -1.24 取得最优终极性能；两种 LLM 辅助方法均未能超越纯 BO。LLANA 更因 LLM 在高维空间中探索退化，14 次评估后崩溃。实验表明，在高维连续参数空间中，数学 surrogate (GP) 仍不可替代，LLM 更适合作为辅助角色而非主力 optimizer。

2. 引言

模拟电路参数优化是芯片设计中的关键步骤。传统方法依赖设计师经验手动调参，效率低且难以保证最优。近年来，强化学习 (RL) 和贝叶斯优化 (BO) 等方法被尝试应用于自动化电路参数优化。与此同时，大语言模型 (LLM) 的快速发展催生了 LLM 辅助优化的新方向，例如 LLAMBO、LLANA 等框架尝试用 LLM 的上下文学习能力替代传统数学 surrogate model。

本实验以 AnalogGym 开源 benchmark [1] 的 NMCF 放大器电路为测试平台 (SKY130 PDK)，系统对比四种优化方法：

- RL: AnalogGym 自带的 R-GCN + DDPG 方法
- BO: 基于 BoTorch 的 Gaussian Process + Expected Improvement
- LLM+BO: 自建 LLM 增强的 BO，LLM 分析优化历史并提议候选参数
- LLANA: LLM 完全替代 GP surrogate 和 acquisition function (arXiv 2406.05250) [2]

3. 方法

3.1. 问题定义

- 电路: NMCF 放大器 (SKY130 PDK)
- 参数空间: 24 维连续参数，归一化到 $[-1, 1]$ 。包括 7 个 MOSFET 的 W/L/M (21 个)、偏置电流 I_b 、补偿电容乘数 M_{C0} 、 M_{C1}
- 优化目标: 最大化 Figure of Merit (FoM)，即 Σ 11 个性能指标得分之和，每个指标得分 ≤ 0 ，最高为 0 (全部达标)
- 仿真器: Ngspice v45，每次仿真运行 AC/DC 分析 (TB_Amplifier_ACDC.cir) 和瞬态分析 (TB_Amplifier_Tran.cir)

11 个评估指标: 温度系数 (TC)、功耗 (Power)、失调电压 (V_{os})、共模抑制比 (CMRR)、直流增益 (DC Gain)、增益带宽积 (GBW)、相位裕度 (PM)、正/负电源抑制比 (PSRP/PSRN)、压摆率 (Slew Rate)、建立时间 (Settling Time)。

3.2. RL 方法 (RGNN + DDPG)

模型采用 R-GCN (关系图卷积网络) 编码电路拓扑为图结构 (28 节点)，每节点包含 12 个晶体管工作点特征 (g_m 、 g_{ds} 、 V_{th} 、 V_{dsat} 等)，由 dev_params.py 生成的 Spice 命令从 DCOP 分析提取。Actor 输出 24 维连续动作 (参数变化方向)，Critic 评估状态-

动作价值。策略为 DDPG（深度确定性策略梯度），前 1000 步纯随机探索，使用 uniform noise ($\sigma = 2$)，batch size 128，memory size 10000。实验运行 200 步。

3.3. Bayesian Optimization

使用 BoTorch [3] 框架：Surrogate model 为 `SingleTaskGP`，Acquisition function 为 Expected Improvement (EI)，初始采样使用 Sobol 序列 10 个点以均匀覆盖参数空间。每轮用 L-BFGS-B 优化 EI 选择下一个评估点。共 10 轮 BO 迭代。

3.4. LLM+BO 方法（自建）

基于自建 `LLMBOsolver`。每轮生成 3 个候选点：1 个来自 BO 的 EI 优化结果，2 个来自 LLM 基于优化历史（参数 $\rightarrow$ FoM）的提议。三个候选点中选 FoM 最优者进入下一轮。LLM 通过 Anthropic SDK 兼容接口调 DeepSeek (`deepseek-v4-pro`)。

3.5. LLANA 方法

LLANA [2] 是 LLM-Enhanced BO 框架，完全用 LLM 替代 GP surrogate 和 acquisition function。采用 discriminative mode：

- Acquisition: LLM 基于历史观察的 few-shot 示例生成候选配置
- Surrogate: LLM 对候选配置预测性能分数，计算 EI 选择最优候选

不依赖任何数学优化器，纯粹靠 LLM 的 in-context learning。实验中设置 `n_templates=1`、`n_gens=3`、`n_candidates=5`（保守参数以避免 API 限流），`n_initial=5`、`n_trials=15`。LLM 使用 DeepSeek-chat（OpenAI 兼容接口；`deepseek-v4-pro` 为推理模型，长 prompt 返回空 content 无法使用）。

4. 实验设置

参数	BO	LLM+BO	RL	LLANA
初始采样	Sobol 10	Sobol 10	Random 100	Random 5
优化步数	10 BO iter	10 iter（每轮 3 点）	200 steps	9 trials（Trial 9 崩溃）
总评估数	20	40	200	14
总耗时	83.8s	1345.7s	1903.9s	1063.5s

表 1 实验参数配置

5. 结果

5.1. 四方法对比

方法	最佳 FoM	评估次数	耗时	样本效率
BO (GP+EI)	-1.3923	20	83.8s	最优
RL (DDPG+RGCN)	-1.2446	200	1903.9s	低
LLM+BO (自建)	-1.5063	40	1345.7s	差
LLANA	-1.7673	14	1063.5s	最差（早停）

表 2 四种方法优化结果对比

5.2. 收敛分析




图 1 收敛曲线对比。左：每次评估的 FoM；中：累积最优 FoM；右：最终结果柱状对比（FoM / 时间 / 评估次数）。

- BO：收敛最快，第 2 个优化步即找到最佳点（-1.39），之后在相近水平波动。
- LLM+BO：波动大（-1.5 ~ -4.1），LLM 提议的点质量不稳定，未超越 BO。
- RL：200 步中 FoM 在 -1.24 ~ -4.0 间波动，最佳在 step 101（刚结束随机探索阶段），后续未见明显改善。
- LLANA：初始随机采样（5 点）最优仅 -1.67，后续 LLM 提议严重趋向退化配置，无法有效探索，Trial 9 因候选点重复触发早停。

5.3. LLANA 的探索失败分析

LLANA 在第 9 轮崩溃（LLM failed to generate candidate points），根本原因是 LLM 在 24 维空间中探索能力严重不足。

LLM 提议类型	出现次数	示例
全零向量	多次	[0, 0, 0, ..., 0]
交替 ±1	3 次	[0, -1, 1, -1, 0, ...]
交替 ±0.5	1 次	[-0.5, 0.5, -0.5, 0.5, ...]
部分零 + 交替值	多次	[0, 0, -1, 0, -0, 1, ...]

表 3 LLM 输出的退化候选配置模式

LLM 只输出整数或半整数的退化配置，未产生具有连续多样性的候选点。每轮 acquisition 需要 5 个有效候选，但实际只能产出约 3 个，5 次重试后仍无法凑齐，触发异常退出。这与 LLANA 原论文在低维超参数优化任务上的成功形成鲜明对比——NMCF 的 24 维连续参数空间超出了当前 LLM（DeepSeek-chat）的数值直觉范围。

5.4. 典型失败模式

四种方法均在以下指标上持续丢分：

- Power（功耗）：NMCF 三级放大器在满足增益/带宽要求时，偏置电流偏大导致功耗超标。
- Phase Margin（相位裕度）：三级运放天然存在相位问题，补偿电容 M_{C0} 、 M_{C1} 调节不够精细。

- Settling Time (建立时间)：与 GBW 和 PM 紧密耦合，难以独立优化。

6. 讨论

6.1. BO 为何效率最高

GP 模型在 24 维空间能有效建模 FoM landscape, EI 在探索与利用间取得良好平衡。每次评估的计算开销仅为 ngspice 仿真 (约 4s), 无额外 API 延迟。30 次评估 (含初始 10 点) 的总耗时不到 90s。

6.2. LLM+BO 为何未达预期

- Prompt 设计简单：仅提供参数值和 FoM, 缺乏电路领域知识注入。
- API 延迟高：每轮 2 次 LLM 调用增加约 60s, 占实验时间的 90% 以上。
- LLM 缺乏数值直觉：在 24 维空间中提议候选点超出了 LLM 的强项范围。
- 候选策略低效：每轮评估 3 个点 (1 BO + 2 LLM), LLM 提议的点质量常不如 EI 优化结果。

6.3. LLANA 为何更差

- LLM surrogate 失效：LLANA 用 LLM 替代 GP 做 surrogate model, 要求 LLM 基于 5-10 个历史样本预测未见点的 FoM。在 24 维空间中, LLM 无法做出有意义预测, 几乎退化为对历史值的机械复述。
- 探索退化：LLM 在 acquisition 阶段反复输出离散退化配置 (全零、交替 ± 1), 丧失了连续空间探索能力。DeepSeek-chat 对「建议一个 24 维 $[-1, 1]$ 内的配置」这类请求倾向于输出结构化而非数值化的回答。
- 样本效率极低：14 次评估后即因候选点重复而崩溃, 最优 FoM (-1.77) 仅来自近似全零配置, 不如任意一次随机初始采样。
- 与 LLM+BO 的本质区别：自建 LLM+BO 保留 GP 做主 optimizer, LLM 仅作辅助提议；LLANA 完全放弃数学 surrogates, 将整个优化过程交给 LLM 的上下文学习——在 24 维电路优化问题上, 这个思路被证明不适用。

6.4. RL 的潜力与局限

RL 达到最佳 FoM (-1.24), 表明 DDPG+R-GCN 有潜力。但 200 步中最佳出现在 step 101 (接近随机阶段结束), 后续未见改善。可能原因：DDPG 超参数未针对此问题调优, 或 GNN 对电路拓扑的编码不够有效。相比 BO, RL 的主要问题是样本效率低——需 10 倍评估次数才取得相近结果。

6.5. 改进方向

- LLM 辅助优化的适用边界：LLANA 实验表明, 纯 LLM 驱动优化在 20+ 维连续参数空间中不适合。LLM 更适合低维 (< 10) 或离散/分类参数空间, 或作为数学 optimizer 的补充而非替代。
- LLM+BO：注入电路领域知识 (器件物理约束、设计规则) 到 prompt; LLM 仅在 BO 停滞时触发; 尝试用更强大的模型或 domain-specific embedding 编码参数空间。
- RL：增加训练步数 (1000+) 观察学习效果; 尝试 PPO 替代 DDPG。

- 实验扩展：在更多 AnalogGym 电路上验证；引入多目标优化（Pareto front）。

7. 结论

在 NMCF 电路参数优化的对比实验中：

1. BO 是当前最实用的方法：20 次评估内达 $FoM = -1.39$ ，效率显著高于所有其他方法。GP 是高维连续空间中最可靠的 surrogate model。
2. RL 展示最佳终极 FoM (-1.24) 但需 200 次评估，样本效率低，适合仿真预算充足的场景。
3. LLM+BO 未带来增益：自建混合方法中，LLM 提议的候选点质量不稳定，API 延迟增加了 90% 以上的时间开销， FoM 反而退化 (-1.51)。
4. LLANA 不适合此类问题：LLM 在 24 维空间中探索退化为离散模式，14 次评估后崩溃，最优仅 -1.77 。纯 LLM-based surrogate 无法替代 GP 在高维连续空间中的建模能力。
5. 所有方法均受限于 NMCF 电路的物理瓶颈（功耗-速度-稳定性 trade-off）。
6. 核心启示：LLM 辅助电路优化的有效路径不是替代数学 optimizer，而是在低维子问题、离散选择或领域知识注入上发挥作用。

8. 参考文献

- [1] CODA-Team, 《AnalogGym: Open-Source Benchmark for Analog Circuit Optimization》. [在线]. 载于: <https://github.com/CODA-Team/AnalogGym>
- [2] T. Liu 和 others, 《LLANA: LLM-Enhanced Bayesian Optimization》. [在线]. 载于: <https://github.com/dekura/LLANA>
- [3] M. Balandat 等, 《BoTorch: A Framework for Efficient Monte-Carlo Bayesian Optimization》. [在线]. 载于: <https://botorch.org/>