

1. 实验背景与目的

模拟电路参数优化是芯片设计中的关键步骤。传统方法依赖设计师经验手动调参，效率低且难以保证最优。近年来，强化学习（RL）和贝叶斯优化（BO）开始被尝试用于自动化电路参数优化；同时，大语言模型（LLM）的快速发展也催生了 LLM 辅助优化的新方向。

本实验基于 AnalogGym 开源 benchmark 的 NMCF 放大器电路（SKY130 PDK），系统对比五种参数优化方法：

- 强化学习（RL）：DDPG + R-GCN
- 贝叶斯优化（BO）：Gaussian Process + Expected Improvement
- 自建 LLM 增强 BO（LLM+BO）
- LLANA v1：LLM 完全替代 GP surrogate 的 BO
- LLANA v2：电路感知 prompt 改进版 LLANA

实验目的是评估 LLM 辅助方法在 24 维连续参数空间中的实际优化能力，与 RL、BO 进行定量对比。

2. 实验平台

2.1. 电路与参数空间

实验使用 AnalogGym 中的 NMCF 放大器电路（Nested Miller Compensation with Feedforward），基于 SKY130 PDK。

- 参数空间：24 维连续参数，归一化到 $[-1, 1]$ 。包括 7 个 MOSFET 的宽/长/倍率（21 个）、偏置电流 I_b 、补偿电容乘数 M_{C0} 、 M_{C1}
- 优化目标：最大化 Figure of Merit (FoM)，即 11 个性能指标得分之和
- 仿真器：Ngspice v45，每次运行 AC、DC 和瞬态分析

2.2. 评估指标

11 个评估指标：温度系数（TC）、功耗（Power）、失调电压（ V_{os} ）、共模抑制比（CMRR）、直流增益（DC Gain）、增益带宽积（GBW）、相位裕度（PM）、正/负电源抑制比（PSRP/PSRN）、压摆率（Slew Rate）、建立时间（Settling Time）。每个指标得分 ≤ 0 ，最高为 0（全部达标）。

3. 实验方法

3.1. RL: DDPG + R-GCN

模型使用 R-GCN（关系图卷积网络）将电路拓扑编码为图结构（28 节点），每节点包含 12 个晶体管工作点特征（ g_m 、 g_{ds} 、 V_{th} 、 V_{dsat} 等）。Actor 输出 24 维连续动作，Critic 评估状态-动作价值。策略为 DDPG，前 100 步纯随机探索，使用 uniform noise（ $\sigma = 2$ ）。实验运行 500 步，batch size 128，memory size 10000。

3.2. BO: GP + EI

使用 BoTorch 框架：surrogate model 为 `SingleTaskGP`，acquisition function 为 Expected Improvement (EI)。初始使用 Sobol 序列采样 10 个点，之后每轮使用 L-BFGS-B 优化 EI 选择下一个评估点。共 10 轮 BO 迭代，总计 20 次评估，seed=42 可复现。

3.3. LLM+BO: 自建 LLM 增强 BO

基于自建 `LLMBOsolver`，BO 的 GP+EI 做主优化器，LLM 提供辅助候选点。每轮生成 3 个候选点：1 个来自 EI 优化，2 个来自 LLM 分析优化历史的提议，从中选最优者进入下一轮。LLM 通过 Anthropic 兼容 API 调用。共 10 轮迭代（10 初始 Sobol + 30 后续评估）。LLM 使用 DeepSeek-chat。

3.4. LLANA v1: LLM 替代 GP

LLANA 是一个用 LLM 完全替代 GP surrogate 和 acquisition function 的 BO 框架。采用 discriminative mode，不依赖任何数学优化器。v1 使用原始的默认 prompt：

- 参数名：x0, x1, ..., x23（无意义索引，LLM 不知道正在调什么）
- 任务描述："NMCF_Amplifier"（仅电路名，无拓扑信息）
- System prompt: "You are an AI assistant that helps people find information."
- 优化指标描述："mean squared error"（不准确，实际是 FoM 最大化）

配置：n_initial=5、n_trials=15、n_templates=1、n_gens=3、n_candidates=5。LLM 使用 DeepSeek-chat。

3.5. LLANA v2: 电路感知 Prompt

在相同 LLANA 框架内，仅修改 prompt 文本内容（不改变核心算法）。三项改进：

1. 参数语义化：将 x0...x23 替换为实际电路参数名（w_M0, L_M0, M_M0, w_M8, ..., Ib, M_C0, M_C1），让 LLM 理解它正在优化 MOSFET 尺寸、偏置电流和补偿电容。这实际上是正确启用了 LLANA 框架的 use_feature_semantics=True 功能。

- 任务描述丰富：将任务描述扩展为包含拓扑信息（3-stage nested Miller compensation with feedforward, SKY130, 7 MOSFET pairs with W/L/M, 11 performance metrics）。
- System prompt 领域化：将 system prompt 替换为 "You are an expert analog circuit designer optimizing amplifier transistor sizing parameters using simulation feedback."。Acquisition 阶段使用 "You are an expert analog circuit designer. Give only the requested output format with no explanation."。

其他配置与 v1 完全一致：n_initial=5、n_trials=15、n_templates=1、n_gens=3、n_candidates=5，相同的 LLM（DeepSeek-chat）。

4. 实验设置

参数	BO	LLM+BO	RL	LLANA v1	LLANA v2
初始采样	Sobol 10	Sobol 10	Random 100	Random 5	Random 5
优化轮次	10 BO iter	10 iter（每轮 3 点）	500 steps	15 trials	15 trials
总评估数	20	40	500	14*	20
总耗时	76.9s	1383.5s	5642.8s	773.8s	1978.8s

表 1 实验参数配置。*LLANA v1 在 Trial 7 崩溃，实际仅完成 14 次评估。

5. 实验结果

5.1. 总体对比

方法	最佳 FoM	评估次数	耗时	样本效率	备注
RL (DDPG+RGCN)	-0.84	500	5642.8s	低	最优 FoM, 但 25× BO 评估数
BO (GP+EI)	-1.39	20	76.9s	最优	同 seed 可复现
LLANA v2	-1.43	20	1978.8s	差	改进 prompt, 未崩溃但未超 BO
LLM+BO (自建)	-1.51	40	1383.5s	差	LLM 提议未带来增益
LLANA v1	-1.77	14	773.8s	最差	Trial 7 崩溃

表 2 五种方法优化结果对比，按 FoM 从高到低排列。

5.2. 收敛曲线




图1 收敛曲线对比。左：每次评估的 FoM；中：累积最优 FoM；右：最终结果柱状对比。

各方法收敛表现：

- BO 收敛最快：第 2 个优化步找到最佳点（-1.39），之后在相近水平波动。Sobol 初始化 + EI 在 24 维空间中有效平衡了探索与利用。
- RL 500 步达到最佳 FoM（-0.84），出现在 step 479。FoM 在 -0.84 至 -6.2 间波动，DDPG 后期持续改善但振荡明显。
- LLANA v2 20 次评估完整运行，best（-1.43）来自初始随机采样，LLM 在后续 15 轮中未提出更优配置。但输出质量稳定，最差仅 -4.82。
- LLM+BO 波动大（-1.5 至 -5.2），LLM 提议的点质量不稳定，API 延迟占实验时间 90% 以上。
- LLANA v1 14 次评估后崩溃，best（-1.77）来自初始采样，后续 LLM 输出退化为全零、交替 ± 1 等离散模式。

5.3. LLANA v1 vs v2：Prompt 消融对比

LLANA v1 与 v2 的唯一区别是 prompt 设计，框架算法和 LLM 模型完全相同，构成一次受控的 prompt 消融实验。

指标	v1	v2	改善	说明
最佳 FoM	-1.77	-1.43	+0.34	均来自初始随机采样
最差 FoM	-44.53	-4.82	+39.72	v2 无灾难性输出
崩溃	是 (Trial 7)	否	—	v2 完整运行 20 次
退化模式	全零、交替 ± 1	无	—	v2 输出合理

表3 LLANA v1 vs v2 消融对比。Prompt 改进使 LLM 从完全不可控变为稳定运行。三项改进的各自效果：

- 参数语义化（效果最显著）： $x_0=0.5$ 对 LLM 毫无意义，但 $w_{M0}=0.5$ 能触发 LLM 预训练中关于 MOSFET 宽度的领域知识，让 LLM 知道它在调什么。

- 任务描述丰富：让 LLM 知道自己在优化三级 NMC 放大器而非抽象的“tabular regression task”，有助于理解各参数之间的耦合关系。
- System prompt 领域化：从通用助手变为电路设计专家角色，激活领域相关的 token 分布。

但无论 prompt 如何改进，LLM 始终未提出优于随机初始采样的配置。BO 在相同 20 次评估下取得 -1.39。

6. 分析讨论

6.1. BO 效率最高的原因

GP 在 24 维空间中能有效建模 FoM landscape，EI 在探索与利用间取得平衡。每次评估仅需 ngspice 仿真（约 4s），无 API 延迟。20 次评估不到 80s，且同 seed 可复现。在有限仿真预算场景下，BO 是最优选择。

6.2. LLM 方法未能超越 BO 的原因

核心问题：高维连续空间中的数值推理能力

24 维参数空间要求精确的数值推理——判断哪些维度组合能提升 FoM、预测参数调整的方向和步长。这是当前 LLM 的固有弱点。LLANA 在低维超参数优化中有报告效果，但在 24 维连续空间中，LLM 的 in-context learning 无法替代 GP 的数学建模。

Prompt 能防崩溃但不能赋能力

v1 $\rightarrow$ v2: FoM 范围收窄 39.72、崩溃消失、输出质量提升。但 LLM 始终未找到优于随机采样的配置。Prompt engineering 的边际收益递减：从 x_0 到 w_{M0} 是 0 $\rightarrow$ 1 的飞跃，但后续更详细的电路描述收益递减。LLM 缺乏对归一化数值（如 $w_{M0}=0.173$ ）的物理直觉。

LLM+BO 为何也未超越 BO

自建 LLM+BO 保留 GP 做主优化器，LLM 仅作辅助提议。但每轮额外 2 次 LLM 调用增加约 60s API 延迟，LLM 提议的候选点在 24 维空间中质量不稳定。边际收益为零。LLM 接收的是归一化到 $[-1, 1]$ 的抽象数值，即使知道“这是 MOSFET 参数”，也无法从 $w_{M0}=0.173$ 推断物理意义和调优方向。

LLM 辅助电路优化的合理路径

不是替代数学 optimizer，而是在低维子问题或离散选择中发挥 LLM 的语义推理优势：分析 trade-off、约束搜索空间、在 BO 停滞时提供基于设计规则的探索方向。

6.3. RL 的改进与局限

从 200 步增加到 500 步，FoM 从 -1.24 提升到 -0.84 ($\Delta = +0.40$)，最佳出现在 step 479，说明 DDPG 后期持续学习。但 500 步耗时约 1.5h，样本效率远低于 BO (20 次/77s)。RL 有进一步优化潜力 (更多训练步数、尝试 PPO)，但需要权衡训练成本。

6.4. 典型失败模式

在 NMCF 电路中，几种性能指标始终难以达标：

- 功耗：三级放大器在满足增益/带宽要求时，偏置电流偏大导致功耗超标。
- 相位裕度：三级运放天然存在相位问题，补偿电容调节不够精细。
- 建立时间：与 GBW 和 PM 紧密耦合，难以独立优化。

7. 总结

1. RL 取得最佳终极性能 (500 步 FoM = -0.84)，但需要 25 倍于 BO 的仿真次数，样本效率低。
2. BO 是最高效的方法：20 次评估、77s 达到 -1.39 ，在有限仿真预算下最优。
3. Prompt 改进显著改善了 LLANA 的表现——消除了崩溃、大幅收窄输出范围——但 LLM 始终未提出优于随机采样的配置。在高维连续空间中，数学 surrogate (GP) 不可替代。
4. LLM+BO 自建方法受限于 LLM 数值推理缺陷和 API 延迟，未带来增益。
5. LLM 辅助电路优化的正确方向是发挥其语义理解和领域知识推理优势 (分析 trade-off、约束搜索空间)，而非替代数学优化器在优化循环中做数值决策。